Khái niệm và quy trình học máy

Module 01 · Deck 02 · Cốt lõi

Nền tảng lập trình cho phân tích và trực quan dữ liệu

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology

Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Trung bình của ai**
2. **Khái niệm**
   - Train và inference
   - Loss và metric
   - Ba tập
3. **Scaler fit ở đâu**
4. **Kiểm tra**
   - Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Trung bình của ai

ltsach@hcmut.edu.vn
Thanh-Sach LE

Số 6.039 thuộc tập nào?

Sau khi chuẩn hóa, trung bình cột `hours` là **6.039**.

- Số đó được tính trên những dòng nào?
- Có được tính trên cả **200 dòng** không?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Khái niệm

Train và inference

- **Train**: ước lượng parameter trên các dòng được phép học.
- **Inference**: dùng parameter đã khóa để ra dự đoán.
- Logistic: parameter là trọng số và intercept. Inference trả xác suất, rồi một lớp.
- Cây: parameter là ngưỡng và lá.
- `max_depth` không được học từ dữ liệu. Đó là **hyperparameter**.

Quy trình học máy
Mục lục
Câu hỏi
Khái niệm
5 Train
Loss
Ba tập
Demo
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Loss và metric

- **Loss**: hàm mà thuật toán tối thiểu hóa. Cross-entropy của logistic là loss.
- **Metric**: thước người đọc. F1 của lớp cần hỗ trợ là metric.
- MAE có thể là loss của một số mô hình, và cũng có thể là metric. Vai trò tùy chỗ nó được dùng.
- Chọn mô hình bằng metric trên dữ liệu phát triển.
- Không chọn bằng loss trên đúng tập vừa fit.

Quy trình học máy
Mục lục
Câu hỏi
Khái niệm
Train
6 Loss
Ba tập
Demo
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Baseline trước mô hình

- Phân loại: luôn đoán lớp đông nhất. Trên 160 dòng, lớp đông là **0**.
- F1 của baseline, 5 fold: **0.000**. Độ lệch giữa fold: 0.000.
- Hồi quy: luôn đoán trung bình điểm của phần train trong fold.
- MAE của baseline: **14.302**. Độ lệch giữa fold: 0.848.
- Hai số này chấm trên các fold của 160 dòng, chưa đụng 40 dòng test.
- Độ lệch giữa các fold không phải khoảng tin cậy.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba tập, ba việc

Tập	Số dòng	Việc được phép
Train	**160**	fit và so sánh mô hình
fit / val của mạng	128 / 32	vòng epoch
Test	**40**	một lần chấm sau khi đã chọn

- Chia bằng `train_test_split`, `test_size=0.2`, `stratify`, seed 261.
- Test có **12** dòng nhãn 1. Số 12 mô tả tập đã khóa.
- Số 12 không phải điểm để chọn mô hình.
- 128 và 32 chỉ dành cho mạng. Các deck cổ điển không cắt thêm `X_val`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Scaler fit ở đâu

ltsach@hcmut.edu.vn
Thanh-Sach LE

Scaler có được học trên cả 200 dòng không?

- **Câu hỏi**, trước khi chạy: trung bình `hours` của scaler có bằng trung bình cả bảng không?
- **Dự đoán**: không bằng, nếu scaler chỉ fit trên 160 dòng.
- Dữ liệu: ba cột số.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mã cốt lõi

```
scaler = StandardScaler().fit(X_train[num])
print([round(v, 3) for v in scaler.mean_])
print([round(v, 3) for v in X_all[num].mean()])
```

- Dòng thứ hai: trung bình được phép học.
- Dòng thứ ba: trung bình cả 200 dòng, kể cả test.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kết quả đã chạy

Tập	hours	sleep	practice
160 dòng train	**6.039**	6.886	3.525
cả 200 dòng	**6.186**	6.903	3.360

- Chênh `0.147` giờ ở cột `hours` không phải sai số của mô hình.
- Đó là **rò dữ liệu**: test đã lọt vào bước fit.
- Cùng lỗi lặp trong từng fold nếu scaler nằm ngoài `Pipeline`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Một thay đổi có kiểm soát

- **Thay đổi**: fit scaler trên cả 200 dòng, in lại trung bình `hours`.
- **Dự đoán**: số in ra bằng `6.186`, trùng dòng "cả bảng".
- Kết quả đúng bằng `6.186`.
- Đó là dấu hiệu rò, không phải mô hình tốt hơn.

Đường học để nhìn overfitting nằm ở deck mạng. Buổi này chưa vẽ đường đó.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Bốn lỗi quy trình

- Xáo trộn lại sau khi đã chia. Seed 261 chỉ tái lập được nếu thứ tự bước giữ nguyên.
- Coi F1 trên tập vừa fit là điểm khái quát.
- Dùng `score` để đoán `needs_support`: nhãn cắt từ điểm, nên đích đã nằm trong feature.
- Gọi mọi số nhỏ hơn là loss. Metric không nhất thiết được tối ưu trực tiếp.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Baseline luôn đoán lớp 0.

1. Vì sao accuracy của baseline này trông ổn?
2. Vì sao F1 của lớp cần hỗ trợ bằng **0**?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- Lớp 1 là **thiểu số**. Accuracy đếm cả lớp 0, nên đoán toàn 0 vẫn được nhiều dòng đúng.
- F1 của lớp cần hỗ trợ chỉ nhìn precision và recall của lớp 1.
- Không có true positive thì F1 bằng **0**.

Làm tiếp trong notebook `demo_02_workflow.ipynb`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- **Train** học parameter. **Inference** chỉ dự đoán. `max_depth` là hyperparameter.
- **Loss** để tối thiểu hóa. **Metric** để chọn và báo cáo.
- 160 dòng để fit và so sánh. 40 dòng test chấm một lần sau khi đã chọn.
- Scaler fit trên 160 dòng: `hours` trung bình **6.039**. Cả 200 dòng là `6.186`. Số sau là rò.
- Baseline đoán toàn lớp 0 có F1 bằng 0. Độ lệch giữa các fold không phải khoảng tin cậy.

ltsach@hcmut.edu.vn
Thanh-Sach LE