Naive Bayes

GaussianNB và MultinomialNB

Module 02 · Deck 03b

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology

Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Cùng khuôn sklearn**
2. **Một cột giờ học**
   - Quan sát 4.45 giờ
   - Likelihood
   - Prior và posterior
3. **Giả định độc lập**
   - Nhân từng cột
   - Cột bị sao chép
4. **So với logistic**
5. **MultinomialNB**
   - Từ câu tới lớp
   - Bảng đếm không có chữ
   - Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mục lục
2 Sklearn
Một cột
Độc lập
So sánh
Đếm

Cùng khuôn sklearn

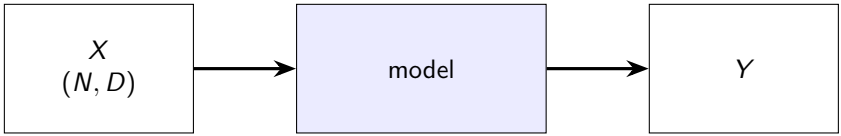
ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng ma trận (N, D), y là lớp

- Khuôn không đổi: X shape (N, D), y shape $(N,)$.
- Ba cột số: phần học `(160, 3)`, test `(40, 3)` chưa đọc.
- Hình một đường mật độ phía sau là lát cắt $D = 1$. Bảng F1 vẫn là $D = 3$.
- Kiểm tra vẫn là fold của 160 dòng, chưa có ma trận `X_val` riêng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

X vào hình chữ nhật, Y đi ra



- X: feature đã biết lúc dự đoán. Không gồm nhãn.
- Cột y để `fit` là nhãn thật. Y trên sơ đồ là đầu ra của mô hình.
- Y không mặc định là một **phân phối xác suất**. Tùy kỹ thuật và tùy hàm:
  - `LinearRegression.predict`: một điểm số
  - `predict` của phân loại: một nhãn
  - `predict_proba`: mỗi dòng là một phân phối trên các lớp

Mục lục
4 Sklearn
Một cột
Độc lập
So sánh
Đếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

fit, báo cáo lớp, rồi predict

```
model = GaussianNB()
model.fit(X_train, y_train)

y_hat = cross_val_predict(model, X_train, y_train, cv=skf)
classification_report(y_train, y_hat)

model.predict(X_new)
```

- `fit` học trên các dòng được phép.
- `classification_report` in precision, recall và F1 từng lớp.
- Deck này đọc **F1 của lớp 1** ở phần so sánh, không đọc test.
- `predict` lúc deploy không có nhãn thật, nên không có báo cáo.

Mục lục
5 Sklearn
Một cột
Độc lập
So sánh
Đếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Một cột giờ học

Mục lục
Sklearn
6 Một cột
Câu hỏi
Likelihood
Prior
Dộc lập
So sánh
Dếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

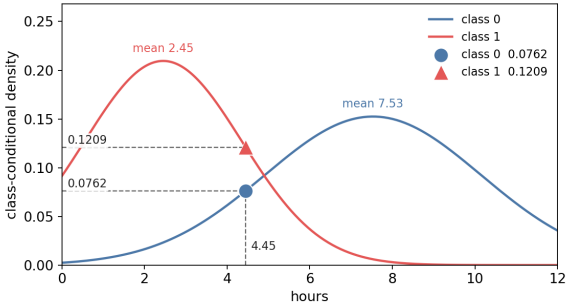
4.45 giờ hợp với lớp nào hơn?

- Trên **160 dòng** dùng để học, không gồm 40 dòng test:
  - lớp 1, cần hỗ trợ, học trung bình **2.45** giờ
  - lớp 0 học trung bình **7.53** giờ
- Đặt một quan sát tại 4.45 giờ. Chỉ nhìn cột này.
- Câu hỏi, trước khi nhớ lớp nào đông hơn: giờ học này hợp với lớp nào hơn?

Mục lục
Sklearn
Một cột
7 Câu hỏi
Likelihood
Prior
Độc lập
So sánh
Dếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hai đường mật độ, một quan sát



- `GaussianNB` ước một phân phối chuẩn cho `hours` của mỗi lớp.
- Hình tròn: mật độ lớp 0. Hình tam giác: mật độ lớp 1. Cùng giờ **4.45**.
- Đây là mô hình **một cột**, chưa phải mô hình ba cột ở bảng F1.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Likelihood: đường nào cao hơn tại vạch đó

- Tại 4.45 giờ:
  - lớp 1: **0.1209**
  - lớp 0: 0.0762
- Tam giác cao hơn hình tròn. **Likelihood** chọn lớp 1.
- Mật độ chưa phải xác suất lớp.
- Phép này chưa nhân với việc lớp 0 đông hơn.

Mục lục
Sklearn
Một cột
Câu hỏi
9 Likelihood
Prior
Độc lập
So sánh
Dếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Prior là tỉ lệ lớp, trước khi thấy giờ học

Lớp	Số dòng	Prior
0	113	113/160
1	47	47/160

- **Prior** không nhìn giờ học.
- Nó chỉ nói lớp nào thường gặp hơn trên 160 dòng.

Mục lục
Sklearn
Một cột
Câu hỏi
Likelihood
10 Prior
Độc lập
So sánh
Dếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Công thức Bayes

$$P(y \mid x) = \frac{P(y)\,P(x \mid y)}{P(x)}$$

- Tử số: **prior** nhân **likelihood** của đúng lớp đó.
- Mẫu số $P(x)$: tổng tử số của hai lớp. Hai posterior cộng thành 1.
- Tại 4.45 giờ, tử số là `0.05385` và `0.03551`.
- $P(x) =$ `0.08936`.
- $0.05385/0.08936 =$ **0.603** cho lớp 0. $0.03551/0.08936 =$ **0.397** cho lớp 1.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Posterior trả lời sau khi đã thấy giờ học



Ý nghĩa

Posterior là xác suất lớp sau khi đã thấy giờ học. Lớp được chọn là lớp có posterior lớn hơn.

- Likelihood chọn lớp 1, vì đường mật độ cao hơn.
- Posterior chọn lớp **0**: `0.603` lớn hơn `0.397`.
- Prior lớp 0 lớn hơn đã lật kết quả, sau khi chia cho cùng một mẫu số.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giả định độc lập

Mục lục
Sklearn
Một cột
13 Độc lập
Nhân cột
Sao chép
So sánh
Đếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Nhiều cột: nhân tiếp từng mật độ

Mục lục
Sklearn
Một cột
Độc lập
14 Nhân cột
Sao chép
So sánh
Dễm

Giả định

Biết lớp rồi, các cột được coi là **độc lập có điều kiện**.

$$P(x_1, x_2 \mid y) = P(x_1 \mid y)\, P(x_2 \mid y)$$

- `fit` học trung bình và phương sai của từng cột, trong từng lớp.
- Dự đoán nhân các mật độ đó.
- Không có `random_state`. `var_smoothing` chỉ thêm một sàn nhỏ cho phương sai.
- Chuẩn hóa không phải nút đầu tiên: mô hình tự ước thang của từng cột.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Sao chép cột giờ học thì lớp có đổi không?

- Cùng mốc 4.45 giờ. Posterior lớp 1 đang là 0.397, lớp được chọn là 0.
- **Câu hỏi**, trước khi chạy: chép cột giờ học thành hai cột giống hệt. Lớp được chọn có đổi không?
- **Dự đoán** đúng nếu giả định đúng: không đổi, vì không có thông tin mới.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mã của phép sao chép

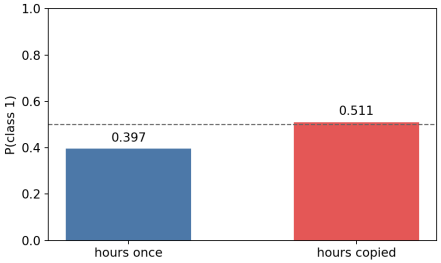
```
one = GaussianNB().fit(hours.reshape(-1, 1), y)
two = GaussianNB().fit(np.column_stack([hours, hours]), y)
p = one.predict_proba([[4.45]])[0, 1]
p2 = two.predict_proba([[4.45, 4.45]])[0, 1]
```

- p là 0.397. p2 là 0.511.
- Hình kế tiếp so hai cột đó với ngưỡng 0.5.

Mục lục
Sklearn
Một cột
Độc lập
Nhân cột
16 Sao chép
So sánh
Dếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng một giờ, đếm hai lần



- Một cột: $P(\text{lớp } 1) = \mathbf{0.397}$. Lớp được chọn là 0.
- Hai cột là bản sao: $P(\text{lớp } 1) = \mathbf{0.511}$. Lớp được chọn thành 1.
- Không có thông tin mới. Phép nhân đã tính một bằng chứng **hai lần**.

Vì sao không cần hai cột tương quan mạnh?

- `hours` và `practice` trên 160 dòng có tương quan **0.059**.
- Generator gieo hai cột riêng, nên chúng gần như không tương quan khi chưa biết lớp.
- Nhãn là một nhát cắt của tổng có cả hai cột.
- Biết lớp rồi, hai cột vẫn có thể mang cùng một phần tin về tổng đó.
- Cột sao chép cho thấy cơ chế nhân, không cần bịa một cặp cột tương quan mạnh.

Mục lục
Sklearn
Một cột
Độc lập
Nhân cột
18 Sao chép
So sánh
Dếm

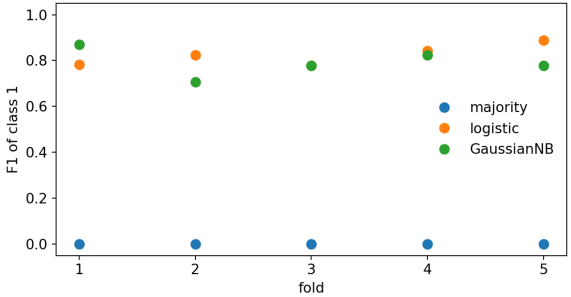
ltsach@hcmut.edu.vn
Thanh-Sach LE

So với logistic

Mục lục
Sklearn
Một cột
Độc lập
19 So sánh
Đếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng năm fold, thêm GaussianNB



- **F1** của lớp 1, cùng `StratifiedKFold`, seed 261, trên 160 dòng.
- Cao hơn thì tốt hơn.
- Baseline: `0.000`.
- GaussianNB: **0.791**, độ lệch giữa fold `0.054`.
- Logistic: **0.823**, độ lệch giữa fold `0.041`.
- Độ lệch giữa các fold không phải khoảng tin cậy.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đọc bảng mà không trao giải

- Hai trung bình cách nhau 0.032.
- Độ lệch fold của GaussianNB là 0.054, lớn hơn khoảng cách đó.
- Chưa đủ để nói logistic thắng.
- Cũng chưa đủ để nói giả định độc lập vô hại.
- Bảng chỉ nói: trên đúng thiết kế này, hai mô hình ở cùng một vùng F1, và cả hai cao hơn baseline.

Mục lục
Sklearn
Một cột
Độc lập
21 So sánh
Đếm

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mục lục
Sklearn
Một cột
Độc lập
So sánh
22 Đếm
Câu văn
Bảng số
Tổng kết

MultinomialNB

ltsach@hcmut.edu.vn
Thanh-Sach LE

MultinomialNB nhận số đếm không âm

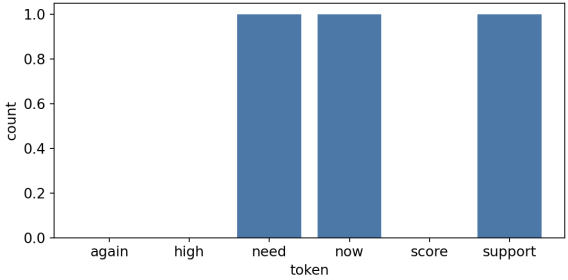
- **MultinomialNB** nhận đặc trưng **không âm**, kiểu số lần xuất hiện.
- Văn bản là một nguồn của vector đó, không phải nguồn duy nhất.
- `hours` có thể là số giờ lẻ. Đó không phải số lần một token xuất hiện.
- Demo chữ dưới đây đổi dạng đặc trưng. Không kết luận Naive Bayes chỉ dành cho văn bản.

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
23 Câu văn
Bảng số
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Một câu đi tới một lớp

- Câu `need support now` nằm trong bốn câu dùng để fit.
- Đây là cơ chế, không phải điểm trên tập giữ riêng.



- Đếm: need 1, now 1, support 1. Ba token kia bằng 0.
- Log-xác suất: lớp 0 là −2.944, lớp 1 là **-0.054**.
- Lớp 1 cao hơn, $p = \mathbf{0.947}$.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Bảng đếm không phải câu chữ

```
X = [[2, 0], [3, 1], [0, 2], [1, 3]]
y = [1, 1, 0, 0]
new = [[2, 0]]
```

- Bốn dòng này được tạo để minh họa và đã chạy.
- `MultinomialNB` đoán dòng mới là lớp **1**, $p = \mathbf{0.900}$.
- Cùng loại đầu vào với vector đếm từ: số không âm. Không có từ nào trong bảng.

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
Câu văn
25 Bảng số
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giới hạn cần mang theo

- Posterior cao không có nghĩa xác suất đã được **hiệu chỉnh**.
- Cũng không phải tác động nhân quả của giờ học.
- Cột sao chép làm lớp đổi dù không thêm tin. Đó là giới hạn của phép nhân.
- F1 `0.791` và `0.823` chưa tách hai mô hình khỏi nhau.

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
Câu văn
26 Bảng số
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Tại 4.45 giờ, likelihood chọn lớp 1 và posterior chọn lớp 0. Sao chép cột giờ học làm posterior lớp 1 thành 0.511.

1. Việc sao chép đã thêm thông tin gì về sinh viên?
2. Vì sao lớp được chọn lại đổi?

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
Câu văn
27 Bảng số
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- Không thêm thông tin. Cột thứ hai là **bản sao**.
- Mô hình vẫn nhân hai mật độ như hai feature **độc lập có điều kiện**.
- Posterior lớp 1 bị kéo từ `0.397` lên `0.511` và vượt `0.5`.
- Lớp được chọn đổi vì phép nhân, không vì sinh viên đổi.

Làm tiếp trong notebook `demo_03_naive_bayes.ipynb`.

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
Câu văn
28 Bảng số
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- **Likelihood**: feature hợp với lớp nào. **Prior**: lớp nào đông hơn trước khi thấy feature.
- **Posterior** nhân hai thứ đó rồi chuẩn hóa. Tại 4.45 giờ, likelihood chọn 1, posterior chọn 0.
- Biết lớp rồi, các cột được nhân như những bằng chứng tách rời.
- Sao chép một cột không thêm tin, nhưng có thể đổi lớp.
- **MultinomialNB** dùng cho số đếm không âm, không chỉ cho văn bản.
- F1 `0.791` và `0.823` chưa đủ để trao giải. Độ lệch fold không phải khoảng tin cậy.

Mục lục
Sklearn
Một cột
Độc lập
So sánh
Đếm
Câu văn
Bảng số
29 Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE