Khoảng cách và biên

kNN, SVC và SVR

Module 02 · Deck 04 · Cốt lõi

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology
Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Cùng khuôn sklearn**
   - Ma trận (N, D)
   - fit và predict
2. **Khoảng cách đổi khi đổi đơn vị**
   - Hai dòng phát triển
3. **Hàng xóm gần nhất**
   - Năm hàng xóm
   - Biên của ba giá trị k
4. **Biên có lề**
   - Đường biên và hai lề
5. **SVR trên hình sin**
   - Kernel chọn đường thẳng hay đường cong
6. **So với mô hình tuyến tính**
   - F1 trên 160 dòng
7. **Kiểm tra**
   - Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng khuôn sklearn

Mục lục
2 Sklearn
Ma trận
Code
Khoảng cách
kNN
SVC
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Vẫn là ma trận (N, D)

- Ba cột số: `hours`, `sleep`, `practice`. $D = 3$.
- Phần được học: $(160, 3)$. Test $(40, 3)$ chưa đọc.
- y phân loại là `needs_support`. y hồi quy là `score`.
- Kiểm tra là fold trong 160 dòng, chưa cắt `X_val`.
- Mẫu mây điểm và hình sin ở sau là hình minh họa. Số của chúng không phải F1 trên `study.csv`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Scaler đứng trong pipeline

```
model = make_pipeline(
    StandardScaler(), KNeighborsClassifier(5))
model.fit(X_train, y_train)
model.predict(X_new)
```

- **fit** nhận X và y. **predict** chỉ nhận X.
- `X_new` có shape $(1, 3)$, không có nhãn.
- SVC và SVR dùng cùng khuôn, đổi lớp ở cuối pipeline.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Khoảng cách đổi khi đổi đơn vị

Mục lục
Sklearn
5 Khoảng cách
Hai dòng
kNN
SVC
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

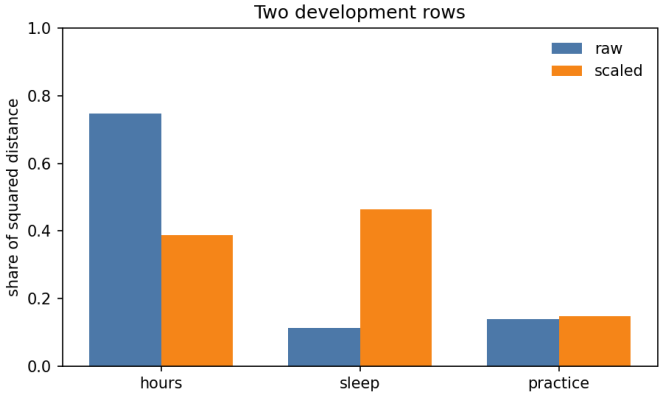
Hai dòng gần nhau theo giờ ngủ, xa nhau theo giờ học

- Cả hai dòng nằm trong **160** dòng được học.
- Dòng A: giờ học `5.06`, ngủ `6.07`, luyện `4`.
- Dòng B: giờ học `0.44`, ngủ `7.87`, luyện `2`.
- Độ lệch chuẩn trên 160 dòng: giờ học `3.354`, ngủ `1.196`, luyện `2.353`.
- Câu hỏi: phần bình phương khoảng cách Euclid thuộc về cột nào?

Mục lục
Sklearn
Khoảng cách
6 Hai dòng
kNN
SVC
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Phần của từng cột, trước và sau scaler



- Trục tung là phần của **bình phương khoảng cách**, cộng lại bằng 1.
- Thô: giờ học **0.747**, ngủ 0.113, luyện 0.140.
- Sau `StandardScaler`: 0.388, **0.464**, 0.148.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Scaler đổi trọng lượng của cột, không đổi hai dòng

- Hai dòng vẫn là A và B. Chỉ cách đo đổi.
- Trên số thô, giờ học chiếm khoảng ba phần tư bình phương khoảng cách.
- Sau scaler, giờ ngủ của cặp này góp nhiều hơn giờ học.
- kNN $k = 5$ không scaler: F1 0.742, độ lệch fold 0.068.
- Có scaler: F1 **0.763**, độ lệch fold 0.046.
- Khoảng cách 0.021 nhỏ hơn độ lệch 0.068. Bảng này chưa chứng minh scaler làm F1 tăng.
- Bảng này chứng minh **khoảng cách** đổi.

Mục lục
Sklearn
Khoảng cách
8 Hai dòng
kNN
SVC
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hàng xóm gần nhất

Mục lục
Sklearn
Khoảng cách
9 kNN
Một điểm
Ba giá trị k
SVC
SVR
So sánh
Kiểm tra

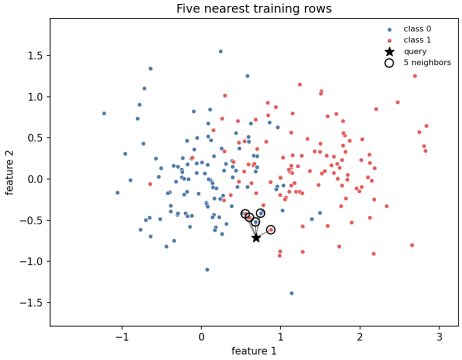
ltsach@hcmut.edu.vn
Thanh-Sach LE

kNN đếm lớp của k dòng gần nhất

- Không có một phương trình cho cả mặt phẳng.
- Tập train được giữ lại. Dự đoán một điểm mới là đọc các dòng gần nó.
- k là hyperparameter. `fit` không học k.
- Mẫu dưới đây có hai feature, hai lớp, seed 261. 224 dòng train, 96 dòng test.

ltsach@hcmut.edu.vn
Thanh-Sach LE

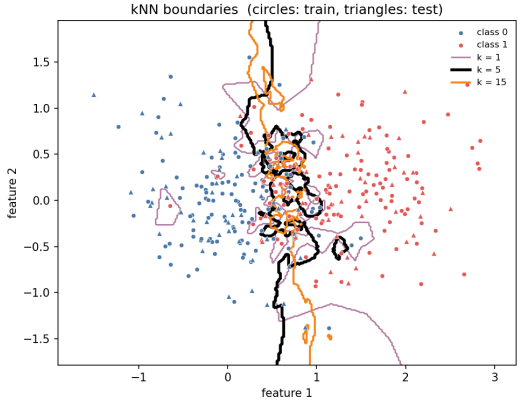
Năm hàng xóm của một điểm test



- Ngôi sao là điểm test `(0.687, -0.711)`.
- Năm vòng tròn là năm dòng train gần nhất.
- Nhãn của năm dòng: `0, 1, 1, 0, 1`. Đa số là lớp **1**.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba giá trị k trên cùng một mây



- Đường tím, $k = 1$, bám từng điểm và tạo mảng nhỏ.
- Đường đen, $k = 5$, và đường cam, $k = 15$, ít gãy hơn.
- Hình tròn là train. Hình tam giác là test.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Accuracy trên mẫu mây, F1 trên 160 dòng

```
KNeighborsClassifier(1)
KNeighborsClassifier(5)
KNeighborsClassifier(15)
```

- Mây điểm, train / test:
  - $k = 1$: 1.000 / 0.844
  - $k = 5$: 0.857 / 0.844
  - $k = 15$: 0.826 / 0.865
- Trên 160 dòng, F1 lớp 1, có scaler:
  - $k = 1$: 0.699, độ lệch 0.071
  - $k = 5$: **0.763**, độ lệch 0.046
  - $k = 15$: 0.778, độ lệch 0.025
- $0.778 - 0.763 = 0.015$, nhỏ hơn độ lệch 0.046. Chưa xếp $k = 15$ thắng $k = 5$.

Khoảng cách và biên
Mục lục
Sklearn
Khoảng cách
kNN
Một điểm
13 Ba giá trị k
SVC
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Biên có lề

Mục lục
Sklearn
Khoảng cách
kNN
14 SVC
Lề
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

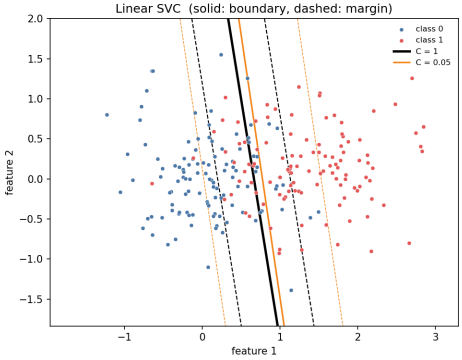
SVC tuyến tính tìm một đường và một lề

- `kernel="linear"`: biên là một đường thẳng trên mặt phẳng hai feature.
- Đường liền là chỗ `decision_function` bằng 0.
- Hai đường đứt là chỗ hàm đó bằng −1 và 1. Đó là **lề**.
- C là hyperparameter. C nhỏ cho phép lề rộng hơn và nhiều điểm nằm trong lề.
- C không phải ngưỡng xác suất 0.5.

Mục lục
Sklearn
Khoảng cách
kNN
SVC
15 Lề
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hai giá trị C trên cùng mẫu mây



- Đen: $C = 1$. Cam: $C = 0.05$. Lề cam rộng hơn.
- Số vector hỗ trợ: 83 khi $C = 1$, 124 khi $C = 0.05$.
- Train / test: $C = 1$ là 0.826 / 0.896. $C = 0.05$ là 0.853 / 0.896.
- Trên mẫu này, C nhỏ không làm test kém đi.

ltsach@hcmut.edu.vn
Thanh-Sach LE

SVC được thiết kế cho hai lớp

```
model = SVC(kernel="linear", C=1)
model.fit(X_train, y_train)
model.predict(X_new)
```

- `kernel` chọn dạng biên. `linear` là một đường thẳng.
- C phạt điểm nằm sai phía lề. C không phải ngưỡng 0.5.
- Mẫu mây ở trên đúng hai lớp, nên `intercept_` có **1** phần tử.
- `predict` trả một nhãn. `predict_proba` mặc định không có và sẽ báo lỗi.
- `decision_function` là độ lệch khỏi biên, không phải xác suất.

Mục lục
Sklearn
Khoảng cách
kNN
SVC
17 Lề
SVR
So sánh
Kiểm tra

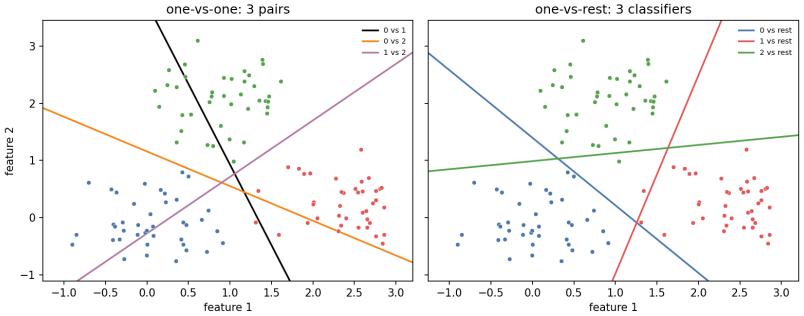
ltsach@hcmut.edu.vn
Thanh-Sach LE

ovo và ovr là hai cách ghép

- **one-vs-one** (ovo): mỗi cặp lớp một bộ. Lớp ngoài cặp không vào bài đó.
- Số bộ ovo là $K(K-1)/2$. $K=3$ ra 3. $K=4$ ra 6.
- **one-vs-rest** (ovr): mỗi lớp chống lại mọi lớp còn lại. Số bộ là K.
- $K=3$ thì cả hai đều ra 3 bộ. Mỗi bộ nhìn một tập điểm khác nhau.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng ba mây, hai cách kẻ đường



- Trái, ovo: đường 0–1 không dùng lớp 2. Mỗi đường là một cặp.
- Phải, ovr: đường 2 vs rest tách lớp 2 khỏi lớp 0 và lớp 1 cùng lúc.

ltsach@hcmut.edu.vn
Thanh-Sach LE

SVC học ovo. Muốn ovr thì bọc thêm

```
ovo = SVC(kernel="linear")
n_ovo = ovo.fit(X, y).intercept_.shape[0]

rest = OneVsRestClassifier(SVC(kernel="linear"))
n_rest = len(rest.fit(X, y).estimators_)
```

- Đã chạy $K = 4$, seed 261: `n_ovo` là 6, `n_rest` là 4.
- `SVC` không có tham số để đổi cách học.
- `decision_function_shape="ovr"` chỉ đổi shape điểm số. Với $K = 4$, shape là `(n, 4)` còn số bộ đã học vẫn là 6.
- `LinearSVC` dùng `multi_class="ovr"`. $K = 4$ thì `coef_` có 4 hàng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Khi nào dùng SVC

- Nên khi bài là **hai lớp**, cần một biên có lề, và các cột đã được chuẩn hóa.
- `kernel="linear"` khi một đường thẳng tách được hai mây, kể cả khi còn chồng nhẹ.
- K lớp chỉ khi K nhỏ. SVC học ovo, nên $K = 10$ là 45 bộ.
- Không dùng khi cần xác suất sẵn.
- Trên 160 dòng, F1 SVC là 0.830, logistic là 0.823. Hiệu 0.007 nhỏ hơn độ lệch fold.

Mục lục
Sklearn
Khoảng cách
kNN
SVC
21 Lề
SVR
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mục lục
Sklearn
Khoảng cách
kNN
SVC
22 SVR
Kernel
So sánh
Kiểm tra

SVR trên hình sin

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba tham số quyết định đường của SVR

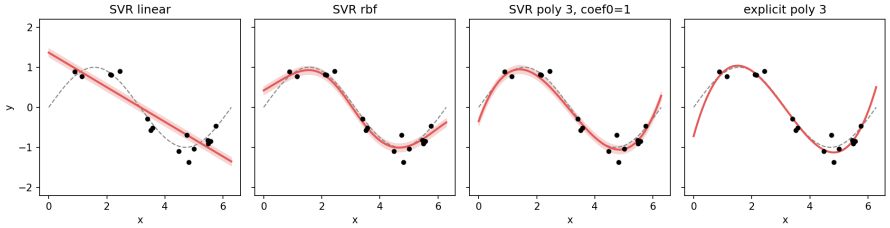
```
SVR(kernel="linear")
SVR(kernel="rbf", epsilon=0.1)
SVR(kernel="poly", degree=3, coef0=1)
```

- `kernel` chọn họ hàm. `linear` ra đường thẳng. `rbf` và `poly` có thể uốn.
- `epsilon` là nửa bề rộng ống. Mặc định `0.1`. Điểm trong ống không bị phạt.
- `epsilon` chỉ đổi bề dày ống. Dạng đường nằm ở `kernel`.
- `C` phạt điểm nằm ngoài ống. `degree` và `coef0` thuộc kernel `poly`.

Khoảng cách và biên
Mục lục
Sklearn
Khoảng cách
kNN
SVC
SVR
23 Kernel
So sánh
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng 16 điểm, bốn cách dựng đường



- Nét đứt xám là $\sin x$. Dải hồng là ống $\epsilon = 0.1$ quanh dự đoán của SVR.
- Cột cuối là `PolynomialFeatures` bậc 3, rồi `LinearRegression`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kernel tuyến tính bỏ sóng

- `kernel="linear"`: MAE train `0.313`, MAE trên hình sin `0.401`. Đường đi thẳng.
- `kernel="rbf"`: `0.129` và **0.099**. Đường uốn theo sóng.
- `kernel="poly"`, `degree=3`, `coef0=1`: `0.135` và `0.073`. Cũng uốn.
- Cùng `poly` nhưng `coef0=0`: MAE trên hình sin `0.682`, kém cả đường thẳng.
- `coef0` được cộng vào trước khi nâng bậc. Bỏ nó thì đa thức thiếu các bậc thấp.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kernel và cột đa thức tường minh

- Biến đổi tường minh tạo cột x, x^2, x^3, rồi `LinearRegression`.
- MAE của cách đó: train `0.122`, trên hình sin `0.098`.
- Kernel `poly` không viết các cột đó. Nó tính $(\gamma xx' + \texttt{coef0})^3$ giữa các điểm.
- Hai cách cùng ý nâng x rồi fit tuyến tính. Hai số MAE không trùng.
- Nên SVR khi đích uốn, như hình sin này. Trên `score` gần thẳng, SVR mặc định có MAE `9.311`, kém đường thẳng `6.430`.

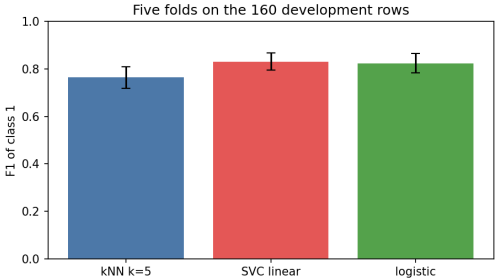
ltsach@hcmut.edu.vn
Thanh-Sach LE

So với mô hình tuyến tính

Mục lục
Sklearn
Khoảng cách
kNN
SVC
SVR
27 So sánh
F1
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

F1 của lớp 1, cùng năm fold



- Càng cao càng tốt. Thanh dọc là **độ lệch giữa fold**, không phải khoảng tin cậy.
- kNN $k = 5$: 0.763, độ lệch 0.046.
- SVC tuyến tính: 0.830, độ lệch 0.036.
- Logistic: 0.823, độ lệch 0.041.
- $0.830 - 0.823 = 0.007$, nhỏ hơn cả hai độ lệch. Chưa xếp SVC thắng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

MAE trên điểm số, cùng 160 dòng

- Càng thấp càng tốt. Vẫn là độ lệch giữa fold, không phải khoảng tin cậy.
- Hồi quy tuyến tính: **6.430**, độ lệch 0.850.
- kNN hồi quy, $k = 5$: 6.918, độ lệch 0.572.
- SVR mặc định: 9.311, độ lệch 0.671.
- Trên bảng gần tuyến tính này, SVR kém đường thẳng.
- Hình sin ở slide trước là một tập khác. Hai kết luận không trộn vào nhau.
- Test 40 dòng chưa được đọc.

Mục lục
Sklearn
Khoảng cách
kNN
SVC
SVR
So sánh
29 F1
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giới hạn cần mang theo

- kNN giữ tập train. Một điểm mới chỉ được đọc qua các hàng xóm.
- Quên scaler làm **khoảng cách** đổi. Trên bảng này, F1 chưa tách hai cách đo.
- C chọn độ rộng của lề. C không phải xác suất.
- SVC nhiều lớp học ovo, số bộ $K(K-1)/2$. ovr học K bộ.
- `kernel` của SVR chọn thẳng hay uốn. `epsilon` chỉ đổi bề dày ống.
- Hình hai feature là mẫu minh họa. Bảng F1 và MAE là ba cột số.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Hai dòng A và B giữ nguyên.

- Bình phương khoảng cách thô: giờ học chiếm `0.747`.
- Sau scaler: giờ học còn `0.388`, giờ ngủ lên `0.464`.

1. Hai dòng có đổi số giờ học, giờ ngủ, số buổi luyện không?
2. Cái gì đổi giữa hai cột xanh và cột cam?
3. F1 `0.742` và `0.763` có đủ để kết luận scaler làm kNN tốt hơn không?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- Hai dòng không đổi. Vẫn là `5.06` giờ và `0.44` giờ.
- Cách đo đổi. Mỗi cột được chia cho độ lệch chuẩn của 160 dòng.
- Giờ học hết chiếm ba phần tư bình phương khoảng cách.
- `0.763 - 0.742 = 0.021`. Độ lệch fold khi không scaler là `0.068`.
- `0.021` nhỏ hơn `0.068`, nên chưa kết luận scaler làm F1 tăng.

Làm tiếp trong các notebook ở `samples/`.

Mục lục
Sklearn
Khoảng cách
kNN
SVC
SVR
So sánh
33 Kiểm tra
Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- Euclid trên số thô để cột có thang lớn kéo khoảng cách.
- **kNN** lấy đa số, hoặc trung bình, của k dòng gần nhất.
- $k = 1$ bám từng điểm. k lớn hơn làm biên ít gãy hơn.
- **SVC** tuyến tính kẻ một đường và một lề. Mặc định không có `predict_proba`.
- SVC học **ovo**. Số bộ là $K(K-1)/2$. ovr học K bộ, qua `OneVsRestClassifier`.
- **SVR**: `kernel="linear"` trên hình sin vẫn thẳng, MAE `0.401`. RBF uốn, MAE `0.099`.
- Trên `score`, SVR mặc định có MAE `9.311`, kém đường thẳng `6.430`.
- F1 `0.830` và `0.823` chưa đủ để xếp SVC trên logistic.

ltsach@hcmut.edu.vn
Thanh-Sach LE