Cây quyết định và ensemble

Cây, forest, và cách ghép

Module 02 · Deck 05

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology

Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Một mẫu hai cột**
   - Một cây và năm cây
2. **Cây hỏi từng cột**
   - Câu hỏi đầu tiên
3. **Nhiều cây**
   - Bagging và tập con cột
4. **Ghép mô hình**
   - Boosting, voting, stacking
5. **Kiểm tra**
   - Tổng kết

ltsach@hcmut.edu.vn
Thanh-Sach LE

Một mẫu hai cột

Mục lục
2 Mẫu nhỏ
Cây và forest
Cây
Forest
Ghép
Kiểm tra

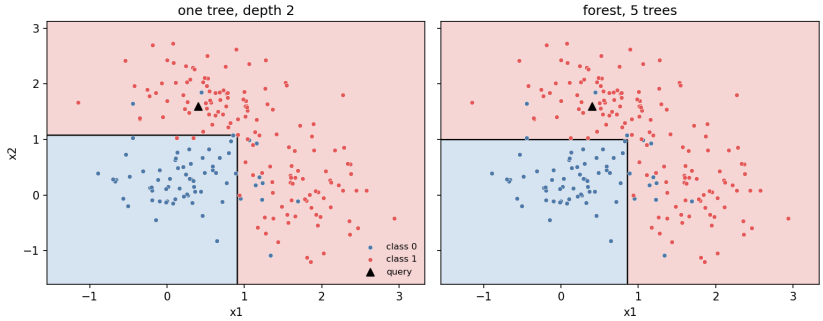
ltsach@hcmut.edu.vn
Thanh-Sach LE

Tập nhỏ để thấy cây hỏi gì

- 210 điểm, hai cột `x1` và `x2`, seed 261. Không phải bảng giờ học.
- Lớp 0 có 70 điểm. Lớp 1 có 140 điểm.
- **Cây** học một lối hỏi. **Forest** học năm cây như vậy, rồi lấy lớp chiếm đa số.
- Cả hai để `max_depth=2`. Mỗi đường đi hỏi tối đa hai lần.

ltsach@hcmut.edu.vn
Thanh-Sach LE

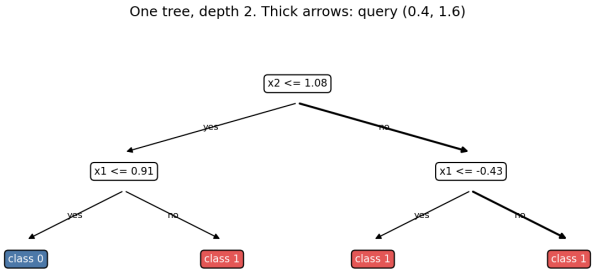
Một cây kẻ góc. Năm cây bỏ phiếu



- Cây hỏi `x2 <= 1.08`. Nếu đúng, hỏi tiếp `x1 <= 0.91`.
- Khi `x2 > 1.08`, cả hai lá đều trả lớp 1.
- Năm câu đầu không trùng: hai cây hỏi x2, ba cây hỏi x1.
- Điểm tam giác `(0.4, 1.6)`: năm phiếu là `1, 1, 1, 0, 1`. Forest trả 1.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Sơ đồ của cây bên trái



- Nhánh yes là phía ngưỡng đúng. Điểm `(0.4, 1.6)` đi hai nhánh no, tới lá lớp 1.
- Hai lá bên phải cùng trả lớp 1. Câu `x1 <= -0.43` không đổi lớp.
- Forest là năm sơ đồ kiểu này. Câu đầu của từng cây không trùng sơ đồ trên.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Code của cây và của forest

```
tree = DecisionTreeClassifier(max_depth=2, random_state=261)
tree.fit(X, y)
tree.predict(X_new)

forest = RandomForestClassifier(
    n_estimators=5, max_depth=2, random_state=261
)
forest.fit(X, y)
forest.predict(X_new)
```

- `X` của mẫu này là `(210, 2)`. `X_new` là `(1, 2)`.
- Trên đúng 210 điểm đã học, accuracy của cây là `0.938`, của forest là `0.933`.
- Hai số này không phải F1 của 160 dòng.

Mục lục
Mẫu nhỏ
6 Cây và forest
Cây
Forest
Ghép
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mục lục
Mẫu nhỏ
7 Cây
Câu hỏi đầu
Forest
Ghép
Kiểm tra

Cây hỏi từng cột

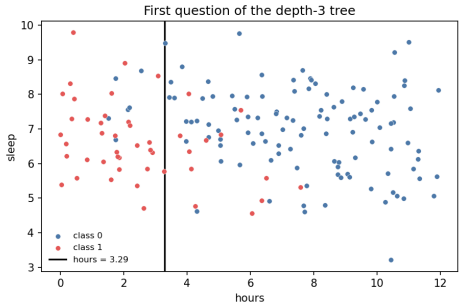
ltsach@hcmut.edu.vn
Thanh-Sach LE

Cây đi theo một lối hỏi

- Cây không cộng các cột. Mỗi nút hỏi **một cột** và một ngưỡng.
- Lá phân loại chứa một lớp. Lá hồi quy chứa trung bình các y trong lá.
- Cây sâu 3, fit trên 160 dòng, hỏi đầu tiên `hours <= 3.29`.
- Nhánh giờ thấp hỏi tiếp `sleep <= 7.31`. Nhánh giờ cao hỏi `practice <= 1.50`.
- `max_depth` giới hạn số câu hỏi trên một đường đi.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi đầu tách giờ học



- Bên trái: 41 dòng, tỉ lệ lớp 1 là 0.854. Bên phải: 119 dòng, tỉ lệ 0.101.
- Đường này chỉ là câu hỏi đầu của cây ba cột.
- Hình vẽ giờ học và giờ ngủ. Câu sau còn dùng số buổi luyện.

Mục lục
Mẫu nhỏ
Cây
9 Câu hỏi đầu
Forest
Ghép
Kiểm tra

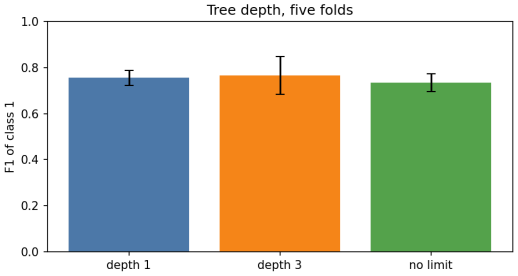
ltsach@hcmut.edu.vn
Thanh-Sach LE

Vì sao cây không cần scaler

- Chuẩn hóa từng cột không đổi thứ tự của cột đó.
- Cùng cây sâu 3 trên dữ liệu đã scale: ngưỡng in ra là `-0.818`.
- Đổi về giờ học, ngưỡng đó vẫn là `3.29`. Cùng các dòng nằm mỗi phía.
- Số `-0.818` không còn là số giờ. Muốn đọc ngưỡng thì fit trên số gốc.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Sâu hơn chưa chắc F1 cao hơn



- Càng cao càng tốt. Thanh dọc là **độ lệch giữa fold**.
- Sâu 1: `0.755`, độ lệch `0.033`. Sâu 3: `0.766`, độ lệch `0.082`.
- Bỏ `max_depth`: `0.735`, độ lệch `0.038`.
- `0.766 - 0.755 = 0.011`, nhỏ hơn `0.082`. Chưa xếp sâu 3 thắng sâu 1.

Nhiều cây

Mục lục
Mẫu nhỏ
Cây
12 Forest
Bagging
Ghép
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

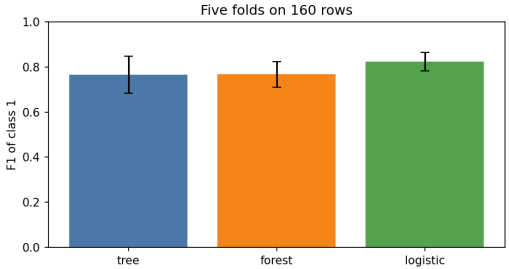
Forest là nhiều cây, không phải một cây lớn

- Bagging lấy nhiều mẫu bootstrap, học nhiều cây, rồi bỏ phiếu hoặc lấy trung bình.
- **Random Forest** còn chọn ngẫu nhiên một tập con cột ở mỗi lần tách.
- Demo dùng 100 cây. Với 3 cột, mỗi lần tách chỉ xét **1** cột.
- Một cây sâu 3 được nhìn cả ba cột khi chọn câu hỏi. Forest thì không.

Mục lục
Mẫu nhỏ
Cây
Forest
13 Bagging
Ghép
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

F1 của lớp 1, cùng năm fold



- Cây sâu 3: `0.766`, độ lệch `0.082`. Forest: `0.767`, độ lệch `0.057`.
- Logistic, có scaler: `0.823`, độ lệch `0.041`.
- `0.767 - 0.766 = 0.001`. Chưa xếp forest thắng cây.
- `0.823 - 0.767 = 0.056`, nhỏ hơn độ lệch của forest. Chưa xếp logistic thắng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

MAE trên điểm số, cùng 160 dòng

- Càng thấp càng tốt. Vẫn là độ lệch giữa fold, không phải khoảng tin cậy.
- Hồi quy tuyến tính: **6.430**, độ lệch 0.850.
- Forest hồi quy: 7.000, độ lệch 0.325. Cây hồi quy sâu 3: 7.971, độ lệch 0.358.
- 7.971 − 6.430 = 1.541, lớn hơn cả hai độ lệch. Cây hồi quy kém đường thẳng.
- 7.000 − 6.430 = 0.570, nhỏ hơn độ lệch 0.850. Chưa xếp đường thẳng thắng forest.

Mục lục
Mẫu nhỏ
Cây
Forest
15 Bagging
Ghép
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ghép mô hình

Mục lục
Mẫu nhỏ
Cây
Forest
16 Ghép
Đọc thêm
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ghép mô hình là phần đọc thêm

- Boosting: cây sau học phần cây trước còn sai. `GradientBoosting`, 50 cây, sâu 2. F1 `0.789`, độ lệch `0.067`.
- Voting cứng của logistic, cây sâu 3 và kNN: F1 `0.814`, độ lệch `0.021`.
- Stacking logistic và cây, lớp cuối là logistic: F1 `0.800`, độ lệch `0.051`.
- Hiệu với logistic `0.823` là `0.034`, `0.009` và `0.023`. Cả ba nhỏ hơn độ lệch của chính cách ghép.
- Thêm mô hình không tự làm F1 cao hơn.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cây và forest không bọc scaler

```
DecisionTreeClassifier(max_depth=3, random_state=261)
RandomForestClassifier(n_estimators=100, random_state=261)
```

- `X` của 160 dòng là `(160, 3)`. `y` là `(160,)`.
- `fit` nhận `X` và `y`. `predict` chỉ nhận `X`.
- Logistic trong biểu đồ F1 có `StandardScaler`. Cây và forest thì không.

Mục lục
Mẫu nhỏ
Cây
Forest
Ghép
18 Đọc thêm
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giới hạn cần mang theo

- Ngưỡng 3.29 là chỗ tách trên tập đang fit. Không phải nguyên nhân cần hỗ trợ.
- Một lá là một vùng dữ liệu, không phải một nhóm nghiệp vụ.
- K-fold chấm mô hình. K-fold không phải một cây trong forest.
- F1 và MAE là hai bảng. Không dùng một số để xếp cả hai.

Mục lục
Mẫu nhỏ
Cây
Forest
Ghép
19 Đọc thêm
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Cây sâu 3 hỏi `hours <= 3.29`. Sau scaler, ngưỡng in ra là `-0.818`.

1. Các dòng bên trái ngưỡng có đổi không?
2. `-0.818` còn là số giờ không?
3. F1 `0.766` và `0.735` có đủ để nói cây không giới hạn kém hơn không?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- Các dòng không đổi. Thứ tự giờ học giữ nguyên, nên hai phía giữ nguyên.
- `-0.818` là giờ học sau khi trừ trung bình và chia độ lệch chuẩn của 160 dòng.
- Đổi ngược lại thì vẫn là `3.29` giờ.
- `0.766 - 0.735 = 0.031`. Độ lệch của cây sâu 3 là `0.082`.
- `0.031` nhỏ hơn `0.082`, nên chưa kết luận cây không giới hạn kém hơn.

Làm tiếp trong notebook ở `samples/`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- Trên mẫu hai cột, một cây hỏi `x2 <= 1.08`. Forest năm cây bỏ phiếu `1, 1, 1, 0, 1`.
- **Cây** trên 160 dòng hỏi đầu `hours <= 3.29`.
- Scaler đổi con số của ngưỡng, không đổi các dòng ở mỗi phía.
- `max_depth` chặn độ sâu. Bỏ giới hạn không làm F1 `0.766` tăng lên.
- **Forest** là nhiều cây. Mỗi lần tách của demo chỉ xét 1 trong 3 cột.
- F1 `0.767` và `0.766` chưa đủ để xếp forest trên một cây.
- Boosting, voting và stacking là phần đọc thêm. Các hiệu với logistic còn nhỏ hơn độ lệch fold.

ltsach@hcmut.edu.vn
Thanh-Sach LE