Mô hình tuyến tính

Hồi quy tuyến tính và logistic regression

Module 02 · Deck 03 · Cốt lõi

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology

Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Khuôn sklearn**
   - Ma trận (N, D)
   - Từ X tới $\hat{y}$
   - fit, báo cáo, deploy
2. **Hồi quy tuyến tính**
   - Mây điểm và đường dự đoán
   - Sai số và đường được chọn
   - Từ một biến sang nhiều feature
3. **Logistic regression**
   - Từ điểm tuyến tính tới lớp
   - Hai ngưỡng và biên quyết định
   - Tham số C
   - Hệ số theo log-odds
4. **Thử đổi giờ học**
5. **So sánh và giới hạn**
   - Tổng kết

1 Mục lục
Sklearn
Hồi quy
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Khuôn sklearn

Mục lục
2 Sklearn
Ma trận
Sơ đồ
Code
Hồi quy
Logistic
Demo
So sánh

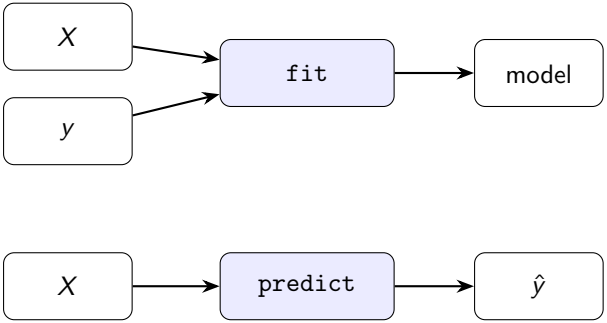
ltsach@hcmut.edu.vn
Thanh-Sach LE

Sklearn nhận X là ma trận

- Mỗi dòng là một sinh viên. Mỗi cột là một feature.
- X có shape (N, D): N dòng, D cột.
- Ba cột số của deck này: $D = 3$.
  - phần phát triển, được học: $(160, 3)$
  - test, để đánh giá cuối: $(40, 3)$
- y là vector $(N,)$. Hồi quy dùng `score`. Phân loại dùng `needs_support`.
- Deck này kiểm bằng từng fold của 160 dòng, chưa cắt riêng một ma trận `X_val`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

X đi vào, $\hat{y}$ đi ra



- **fit**: cần cả X và y. Mô hình học tham số.
- **predict**: chỉ cần X. Mô hình trả $\hat{y}$.
- Lúc deploy không có y thật, nên không có báo cáo sai số.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba việc, ba đoạn gọi

```
model = make_pipeline(StandardScaler(), LinearRegression())
model.fit(X_train, y_train)

y_hat = cross_val_predict(model, X_train, y_train, cv=kf)
mean_absolute_error(y_train, y_hat)

model.predict(X_new)
```

- `fit`: học trên `(160, 3)`.
- `cross_val_predict` tự fit lại từng fold. Đó là bản báo cáo hồi quy của deck này.
- Sklearn không có hàm tên `regression_report`. Phân loại dùng `classification_report`.
- `X_new` có shape $(1, 3)$. Không truyền y.

Mô hình tuyến tính
Mục lục
Sklearn
Ma trận
Sơ đồ
5 Code
Hồi quy
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hồi quy tuyến tính

Mục lục
Sklearn
6 Hồi quy
Mây điểm
Sai số
Nhiều cột
Logistic
Demo
So sánh

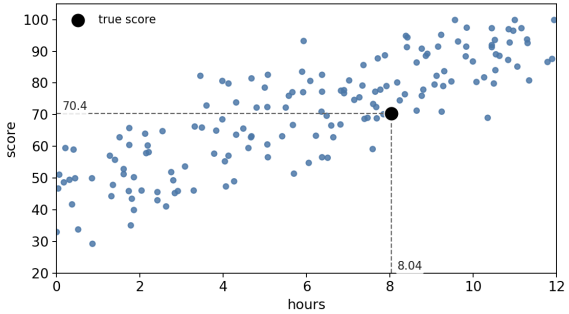
ltsach@hcmut.edu.vn
Thanh-Sach LE

Một sinh viên học 8 giờ sẽ được bao nhiêu điểm?

- Trong **160 dòng phát triển** có một sinh viên:
  - học 8.04 giờ, ngủ 8.32 giờ, luyện 2 buổi
  - điểm thật 70.4
- Trước khi gọi thư viện, hãy nhìn mây điểm:
  - đường nào cũng chấp nhận được?
  - hay có một đường đáng chọn hơn?
- **Tập test** 40 dòng được giữ lại cho đánh giá cuối.

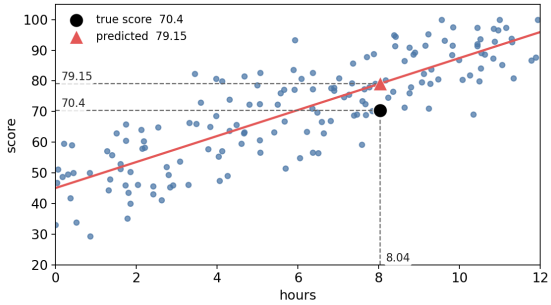
ltsach@hcmut.edu.vn
Thanh-Sach LE

Dữ liệu trông như thế nào?



- Hình tròn: sinh viên `8.04` giờ, điểm thật **70.4**.
- Đường đứt nét dóng xuống trục giờ và sang trục điểm.
- `sleep` và `practice` không có trên hình. Đây là **lát cắt** một feature.

Đường cao bao nhiêu thì đó là điểm dự đoán

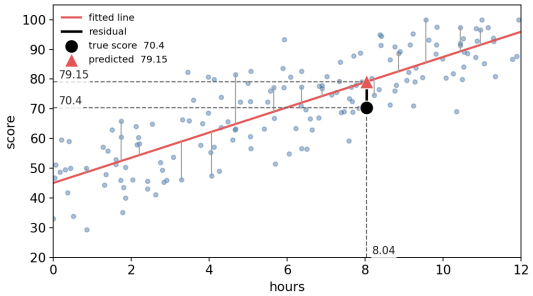


- Hình tròn: điểm thật **70.4**.
- Hình tam giác: **giá trị dự đoán** `79.15`.
- Cùng một giờ, hai điểm khác nhau, hai ký hiệu. Đường đứt nét dóng về hai trục.

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
9 Mây điểm
Sai số
Nhiều cột
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đoạn thẳng đứng là sai số của một dòng

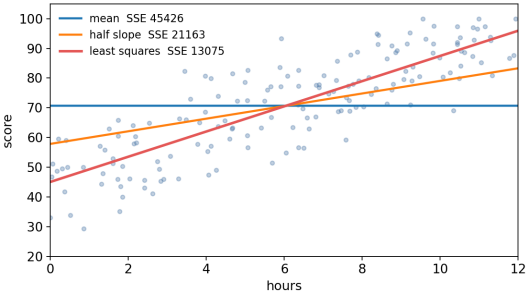


- Đoạn liền nối hình tròn và hình tam giác là **residual**: $70.4 - 79.15 = $ **-8.75**.
- Âm nghĩa là hình tam giác nằm **trên** hình tròn.
- Đây là sai số **một quan sát**, chưa phải MAE của mô hình.

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
Mây điểm
10 Sai số
Nhiều cột
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Vì sao không lấy đường nằm ngang?



- **SSE**: tổng bình phương sai số trên 160 dòng.
- Đường trung bình: 45426. Đường dốc một nửa: 21163.
- Đường bình phương tối thiểu: **13075**, nhỏ nhất.
- **Fit** chọn đường đó.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Công thức một biến, đọc trên đúng sinh viên này

$$\hat{y} = 4.24\,\text{hours} + 45.06$$

- Kiểm tra: $4.24 \times 8.04 + 45.06 = \mathbf{79.15}$.
- **4.24**: số điểm đường này tăng khi giờ học tăng 1.
- Đơn vị còn là **giờ gốc**, chưa qua `StandardScaler`.
- Các feature khác chưa có trong công thức này.

ltsach@hcmut.edu.vn
Thanh-Sach LE

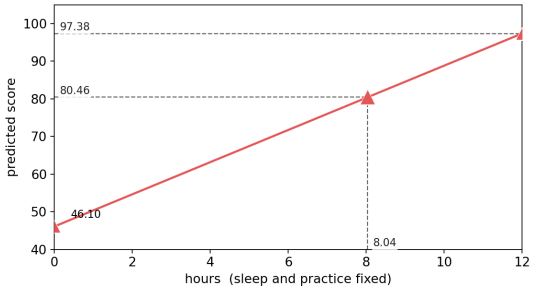
Ba feature: các hình vừa rồi là một lát cắt

$$\hat{y} = w_1 \,\text{hours} + w_2 \,\text{sleep} + w_3 \,\text{practice} + b$$

- Đầu vào: ba cột số. Đầu ra: **một điểm**. Không có ngưỡng lớp.
- Cùng sinh viên, mô hình ba feature cho $\hat{y} = \mathbf{80.46}$.
- Residual: $70.4 - 80.46 = \mathbf{-10.06}$.
- Thêm feature **không** kéo mọi dòng lại gần đường.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đổi giờ học, giữ nguyên hai cột kia



- Cả ba đều là hình tam giác: **điểm dự đoán**. Ngủ 8.32 và luyện 2 đứng yên.
- Tam giác lớn: **80.46** tại 8.04 giờ. Hai tam giác nhỏ: 46.10 và 97.38.
- Đây là **phản ứng của mô hình đã fit**, chưa phải bằng chứng học thêm làm điểm tăng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Thư viện fit cái gì?

- `LinearRegression` tìm hệ số làm **SSE** nhỏ nhất.
- Bản không phạt gần như không có **hyperparameter**.
- **Ridge** và **Lasso** là phần đọc thêm.
- Pipeline có `StandardScaler` cho **cùng** $\hat{y}$ với hồi quy trên số gốc.
- Hệ số trong pipeline nằm trên **độ lệch chuẩn**, không còn là điểm trên mỗi giờ.

Mục lục
Sklearn
Hồi quy
Mây điểm
Sai số
15 Nhiều cột
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đoạn mã của mô hình ba feature

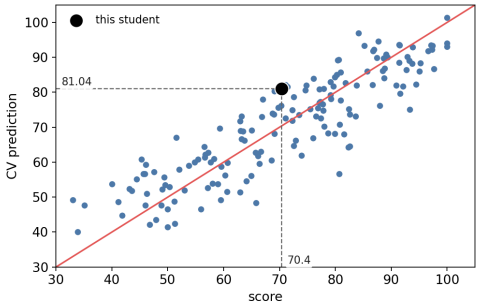
```
lin = make_pipeline(StandardScaler(), LinearRegression())
hat = cross_val_predict(lin, X_train, y_score, cv=kf)
```

- **KFold**: 5 phần, xáo trộn, seed 261, chỉ trên 160 dòng.
- Mỗi dòng được một mô hình **không học trên chính nó** dự đoán.

Mục lục
Sklearn
Hồi quy
Mây điểm
Sai số
16 Nhiều cột
Logistic
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

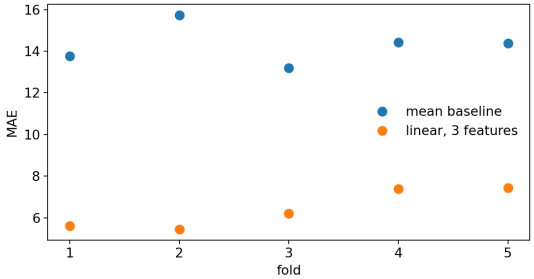
Giá trị thật và giá trị cross-validation



- Hình tròn: sinh viên 8.04 giờ. Đường dóng đọc được điểm thật 70.4 và CV **81.04**.
- Sai số tuyệt đối của dòng này: **10.64**.
- Đường chéo: dự đoán trùng điểm thật.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Baseline và hồi quy, cùng năm fold



- **MAE** càng thấp càng tốt.
- **Baseline** trung bình: 14.302. Độ lệch giữa fold: 0.848.
- Hồi quy: **6.430**. Độ lệch giữa fold: 0.850.
- Độ lệch giữa các fold **không** phải khoảng tin cậy.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba số của cùng một sinh viên không cùng một vai

Số	Vai
81.04	điểm CV dự đoán
10.64	sai số tuyệt đối của một dòng
6.430	MAE trung bình trên năm fold

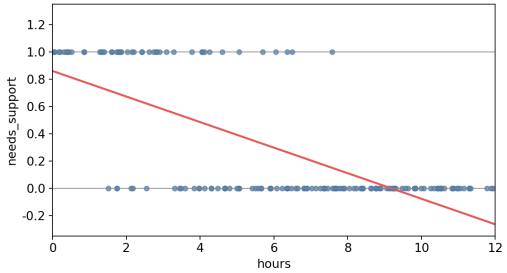
- MAE của một dòng tính được, bằng 10.64.
- Số đó không đại diện cho **khả năng khái quát**.
- F1 không dùng cho bài đoán điểm.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Logistic regression

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đường thẳng có đoán được nhãn 0/1 không?



- Hồi quy `needs_support` theo giờ học.
- Giá trị fit: thấp nhất -0.259, cao nhất 0.859.
- **35/160** dòng rơi dưới 0.
- Một số không bị chặn trong $[0, 1]$ thì không đọc như **xác suất**.

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
Logistic
21 Xác suất
Ngưỡng
Tham số C
Hệ số
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Từ cột số tới một lớp

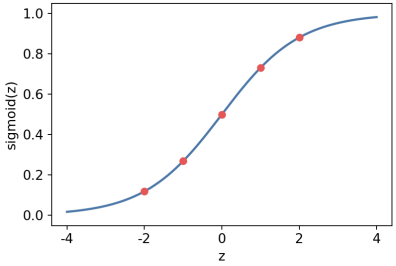
`hours, sleep, practice` $\to z \to \sigma(z) \to p \to$ ngưỡng 0.5 $\to$ lớp

1. z: **điểm tuyến tính**
2. $\sigma(z)$: ép z vào $(0, 1)$, ra **xác suất** p
3. Ngưỡng **0.5**: quyết định của `predict`, không phải thứ mô hình học từ dữ liệu
4. Lớp: kết quả sau ngưỡng

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
Logistic
22 Xác suất
Ngưỡng
Tham số C
Hệ số
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cùng một bước z không cộng một lượng p cố định



z	p
-2	0.119
-1	0.269
0	0.500
1	0.731
2	0.881

- $z = 0$ cho $p = \mathbf{0.500}$.
- Từ $z = 0$ lên $z = 1$: p tăng $\mathbf{0.231}$.
- Từ $z = 1$ lên $z = 2$: p chỉ tăng $\mathbf{0.150}$.

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
Logistic
23 Xác suất
Ngưỡng
Tham số C
Hệ số
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Một dòng train, đọc đủ bốn bước

- Dòng có p gần 0.5 nhất trong 160 dòng.
- Các số dưới đây là **hàm đã fit**, không phải điểm test.

hours	sleep	practice	z	p	lớp	score
3.78	6.80	3	0.029	**0.507**	**1**	57.7

- `score` không phải đầu vào.
- Cột này chỉ cho biết nhãn trong file được cắt thế nào.

Mô hình tuyến tính

Mục lục

Sklearn

Hồi quy

Logistic

24 Xác suất

Ngưỡng

Tham số C

Hệ số

Demo

So sánh

ltsach@hcmut.edu.vn

Thanh-Sach LE

Ngưỡng xác suất và ngưỡng tạo nhãn là hai việc

- Nhãn trong file bằng 1 khi `score` < 60.
- Lớp của `predict` bằng 1 khi $p \geq 0.5$.

Hai dòng trong cùng 160 dòng:

- `3.78` giờ, điểm `57.7`: nhãn 1 và $p = 0.507$, lớp 1. Hai quy tắc gặp nhau.
- `6.59` giờ, ngủ `4.92`, luyện `0`, điểm `66.7`:
  - nhãn file là **0**
  - $p = 0.513$ nên lớp mô hình là **1**

ltsach@hcmut.edu.vn
Thanh-Sach LE

C chọn mức bám vào dữ liệu

Ý nghĩa của C

C quyết định mô hình được phép bám nhãn đến đâu.

- C lớn: bám dữ liệu hơn. Hệ số được phép lớn.
- C nhỏ: hệ số bị kéo về **0**. Mô hình ít tách hai lớp.
- C là hyperparameter. `fit` không học C. Mặc định $C = 1$.
- Trong thư viện, C nhân phần sai trên dữ liệu, không nhân $\|w\|^2$.
- C không phải ngưỡng $p = 0.5$. Các slide trước dùng $C = 1$.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hai giá trị C, cùng 160 dòng

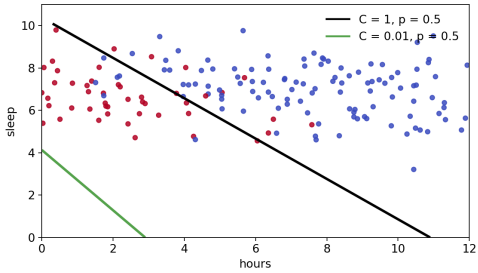
```
wide = make_pipeline(
    StandardScaler(),
    LogisticRegression(C=1, max_iter=500),
)
tight = make_pipeline(
    StandardScaler(),
    LogisticRegression(C=0.01, max_iter=500),
)
wide.fit(X_train, y_train)
tight.fit(X_train, y_train)
```

- Cùng ba feature, cùng scaler.
- Hệ số `hours`: $C = 1$ cho **-2.817**. $C = 0.01$ cho **-0.380**.

Mục lục
Sklearn
Hồi quy
Logistic
Xác suất
Ngưỡng
27 Tham số C
Hệ số
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Biên $p = 0.5$ trên lát cắt hai chiều



- Chỉ `hours` và `sleep`. `practice` không có trên hình.
- Đỏ: nhãn 1. Xanh dương: nhãn 0.
- Đường đen: $C = 1$. Đường xanh lá: $C = 0.01$, nằm **dưới đám mây**.
- Trong vùng có dữ liệu, mô hình $C = 0.01$ không đạt $p = 0.5$.

ltsach@hcmut.edu.vn
Thanh-Sach LE

C nhỏ đẩy biên ra khỏi đám mây

Trên lát cắt hai feature, đếm lớp 1 mà mô hình gán trên chính 160 dòng fit:

C	tỉ lệ đoán lớp 1
1	**0.269**
0.01	**0.000**

- Với $C = 0.01$, suốt đám mây mô hình đoán lớp 0.
- Đây là dự đoán **in-sample** của lát cắt.
- Chưa phải F1 của cross-validation.

Mô hình tuyến tính

Mục lục

Sklearn

Hồi quy

Logistic

Xác suất

Ngưỡng

29 Tham số C

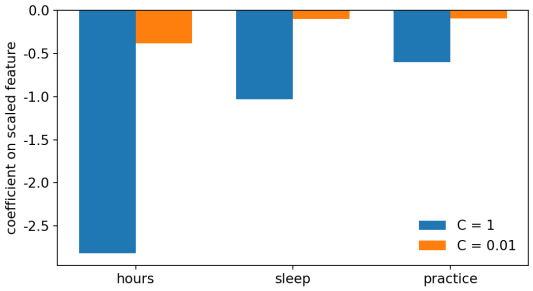
Hệ số

Demo

So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Hệ số là bước của log-odds, trên đơn vị đã chuẩn hóa



- Ba feature, $C = 1$:
  - hours **-2.817**, sleep -1.028, practice -0.602
- Với $C = 0.01$, hours còn **-0.380**.
- Một đơn vị ở đây là **một độ lệch chuẩn** trên 160 dòng train.

ltsach@hcmut.edu.vn
Thanh-Sach LE

-2.817 **không phải** -2.817 **xác suất**

Tại dòng $z = 0.029$, $p = 0.507$. Cộng đúng hệ số hours:

$$z' = 0.029 + (-2.817) = -2.788, \qquad p' = \mathbf{0.058}.$$

- Xác suất giảm **0.449**, không giảm 2.817.
- Cùng một bước z, ở chỗ khác trên sigmoid, p đổi một lượng khác.
- Phép cộng này nằm **trong công thức**.
- Không phải một sinh viên được học thêm một độ lệch chuẩn ngoài đời.

Mô hình tuyến tính
Mục lục
Sklearn
Hồi quy
Logistic
Xác suất
Ngưỡng
Tham số C
31 Hệ số
Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mục lục
Sklearn
Hồi quy
Logistic
32 Demo
So sánh

Thử đổi giờ học

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tăng giờ học thì p đi về đâu?

- **Câu hỏi**, trước khi vẽ:
  - ngủ `6.80` và luyện 3 giữ nguyên
  - tăng `hours` làm $P(\texttt{needs_support} = 1)$ tăng hay giảm?
- **Dự đoán** từ hệ số âm: giảm.
- Hình kế tiếp kiểm tra dự đoán đó.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Mã cốt lõi

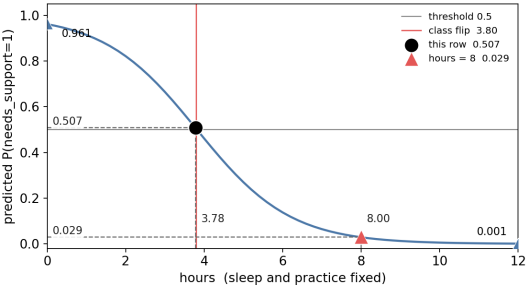
```
grid = pd.DataFrame({
    "hours": [3.78, 8.00],
    "sleep": [6.80, 6.80],
    "practice": [3, 3],
})
p = logreg.predict_proba(grid)[:, 1]
```

- grid chỉ đổi **giờ học**.
- Hai xác suất: 0.507 và 0.029.
- Đường đầy đủ từ 0 đến 12 giờ ở hình kế tiếp.

Mục lục
Sklearn
Hồi quy
Logistic
34 Demo
So sánh

ltsach@hcmut.edu.vn
Thanh-Sach LE

Xác suất theo giờ học, hai cột kia cố định



- Hình tròn: dòng thật, 3.78 giờ, $p = \mathbf{0.507}$.
- Hình tam giác đỏ: giờ học đổi thành 8.00, $p = \mathbf{0.029}$.
- Hai tam giác nhỏ: $p = 0.961$ tại 0 giờ và 0.001 tại 12 giờ. Lớp đổi tại **3.80** giờ.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Trước và sau

hours	p	lớp
3.78	0.507	1
8.00	**0.029**	**0**

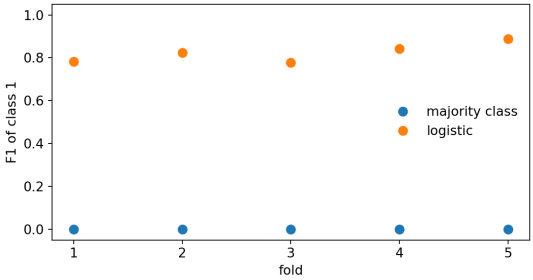
- Ngủ và luyện không đổi.
- Kết luận được: hàm đã fit **giảm** p khi giờ học trong đầu vào tăng.
- Không kết luận được: học thêm gây ra việc hết cần hỗ trợ.

ltsach@hcmut.edu.vn
Thanh-Sach LE

So sánh và giới hạn

ltsach@hcmut.edu.vn
Thanh-Sach LE

F1 trên cùng năm fold



- **F1** của lớp 1: càng cao càng tốt.
- **Baseline** luôn đoán 0: trung bình `0.000`.
- Logistic: **0.823**. Độ lệch giữa fold: `0.041`.
- Độ lệch này không phải khoảng tin cậy.
- GaussianNB dùng cùng các fold ở phần Naive Bayes.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giới hạn cần mang theo

- p từ sigmoid là đầu ra của mô hình.
- Buổi này chưa kiểm tra p đã được **hiệu chỉnh**.
- Hệ số nói về **log-odds** trên thang chuẩn hóa:
  - không phải một mức đổi xác suất cố định
  - không phải nguyên nhân
- Hình một hoặc hai feature là **lát cắt**.
- Bảng F1 và MAE là mô hình **ba feature**, chấm bằng cross-validation trên 160 dòng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Sinh viên 8.04 giờ có điểm 70.4.

- Lát cắt một biến cho 79.15.
- Sai số một dòng là −8.75.
- MAE năm fold của mô hình ba feature là 6.430.

1. Số nào là **giá trị dự đoán**?
2. Số nào là **sai số một quan sát**?
3. Số nào là **metric** trên tập phát triển?
4. MAE của riêng dòng này có thay được 6.430 không?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- **79.15**: điểm dự đoán của lát cắt một biến.
- **-8.75**: residual của đúng dòng đó.
- Trị tuyệt đối `8.75` là MAE của **một quan sát**.
- Số đó không đại diện cho **6.430**.
- `6.430`: trung bình MAE của năm fold.
- F1 không thuộc bài đoán điểm.

Làm tiếp trong notebook `demo_03_linear.ipynb`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- **Hồi quy tuyến tính** dự đoán một số. Fit chọn đường có SSE nhỏ nhất.
- **Residual** một dòng khác **MAE** trên nhiều fold.
- Đường thẳng trên nhãn 0/1 không phải xác suất.
- **Logistic regression**: $z \to$ sigmoid $\to p \to$ ngưỡng $\to$ lớp.
- Ngưỡng $p = 0.5$ khác ngưỡng $\texttt{score} < 60$.
- Hệ số là bước **log-odds** sau chuẩn hóa, không phải mức đổi xác suất cố định.
- C chọn mức bám dữ liệu. C nhỏ kéo hệ số về 0, không phải ngưỡng xác suất.
- Đổi đầu vào cho thấy phản ứng của hàm đã fit, không chứng minh nguyên nhân.

ltsach@hcmut.edu.vn
Thanh-Sach LE