Học không giám sát

K-means và PCA

Module 02 · Deck 06

CO5177 · Học kỳ 261

Thanh-Sach LE

✉ ltsach@hcmut.edu.vn

Faculty of Computer Science and Engineering
Ho Chi Minh City University of Technology

Ho Chi Minh City. Học kỳ 261

Mục lục

1. **Chỉ có ma trận X**
   - Ba cột số
2. **K-means**
   - Gán điểm, rồi dời tâm
3. **PCA**
   - Một hướng dài, một hướng mỏng
   - Hướng có phương sai lớn
4. **Kiểm tra**
   - Tổng kết

1 Mục lục
Không có y
K-means
PCA
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Chỉ có ma trận X

ltsach@hcmut.edu.vn
Thanh-Sach LE

K-means và PCA không nhận target

- Đầu vào là `hours`, `sleep`, `practice`. Không có `needs_support`.
- Không có nhãn đúng trong phép fit, nên deck này **không báo F1**.
- Fit trên cả **200** dòng. Không có tập test để chấm accuracy.
- Cột `major` không được đưa vào. Ba ngành có 76, 62 và 62 dòng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

K-means

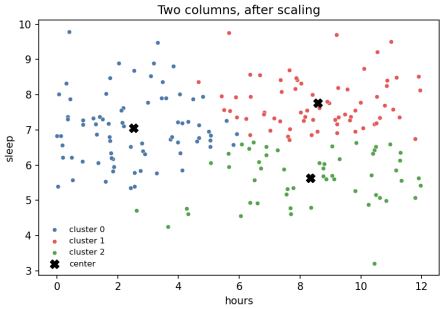
ltsach@hcmut.edu.vn
Thanh-Sach LE

Hai bước lặp của K-means

- k do mình chọn. Demo dùng $k = 3$, `n_init=10`, seed 261.
- Gán mỗi dòng vào **tâm gần nhất**.
- Tâm mới là trung bình các dòng vừa được gán vào cụm đó.
- Nhãn $0, 1, 2$ là số thứ tự cụm. Không phải ngành, không phải `needs_support`.
- Cần scaler. Khoảng cách tới tâm bị cột có thang lớn kéo, cùng lý do với kNN.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Minh họa trên hai cột



- Chỉ `hours` và `sleep`, sau scaler. Dấu X là ba tâm, vẽ lại trên số gốc.
- Cỡ cụm của hình này: 77, 68, 55.
- Đây không phải bài ba cột. Bài ba cột có cỡ 59, 80, 61.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Ba cột, và inertia giảm khi tăng k

- $k = 2$: cỡ 101, 99. Inertia 439.4.
- $k = 3$: cỡ 59, 80, 61. Inertia **343.0**.
- $k = 4$: cỡ 45, 64, 55, 36. Inertia 273.0.
- **Inertia** là tổng bình phương khoảng cách tới tâm. Thêm tâm thì số này giảm.
- Mức giảm không chứng minh cụm mới có nghĩa hơn.
- Cỡ 59, 80, 61 không trùng 76, 62, 62 của ba ngành.

ltsach@hcmut.edu.vn
Thanh-Sach LE

PCA

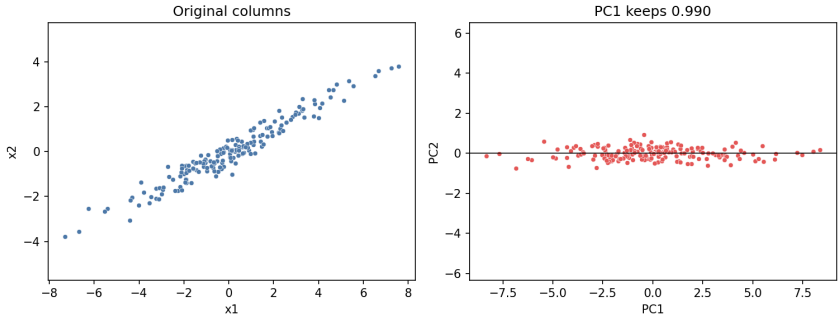
ltsach@hcmut.edu.vn
Thanh-Sach LE

Một đám dài, không phải bảng giờ học

- 180 điểm, hai cột x1 và x2, seed 261.
- Phương sai hai cột là 6.678 và 1.949. Cả hai cột đều có độ trải.
- Đám nằm theo một hướng chéo. Hướng vuông góc với đám thì rất mỏng.
- Mẫu này không qua scaler. Hai cột đang cùng một đơn vị.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Xoay để chiều dài thành PC1



- Trái là hai cột gốc. Phải là cùng các điểm sau PCA.
- PC1 giữ **0.990**. PC2 còn 0.010.
- Bỏ PC2 thì còn một cột, và vẫn giữ 0.990 phương sai.

Giữ một thành phần

```
pca = PCA(n_components=1, random_state=261)
kept = pca.fit_transform(X)
```

- `X` là `(180, 2)`. `kept` là `(180, 1)`.
- Bảng ba cột giờ học là tập khác. Ở đó hai trục đầu chỉ giữ `0.680`.

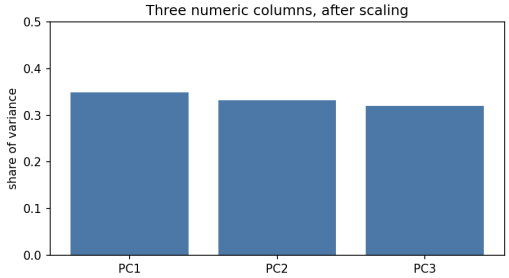
ltsach@hcmut.edu.vn
Thanh-Sach LE

PCA tìm hướng, không tìm lớp

- Sau scaler, **PCA** tìm các hướng mới sao cho phương sai trên hướng đó lớn.
- Không dùng nhãn. Không có tham số để làm khớp `needs_support`.
- `n_components=2` là để vẽ mặt phẳng. Cột thứ ba vẫn còn.

ltsach@hcmut.edu.vn
Thanh-Sach LE

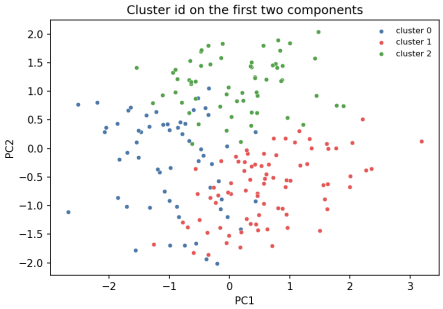
Ba phần phương sai gần bằng nhau



- Ba phần: 0.348, 0.332, 0.320.
- Hai trục đầu giữ 0.680. Phần 0.320 không nằm trên hình hai trục.

ltsach@hcmut.edu.vn
Thanh-Sach LE

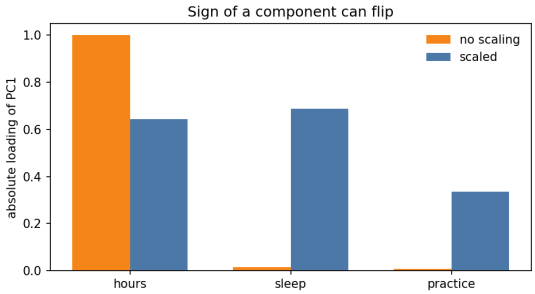
Màu trên hình là số cụm



- Màu là nhãn K-means của ba cột, không phải ngành.
- Các cụm còn chồng trên mặt phẳng này.
- Hai trục chưa phải toàn bộ bảng.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Không scale thì trục thứ nhất là giờ học



- Không scale: PC1 giữ 0.626 phương sai. Trị tuyệt đối hệ số là 1.000, 0.015, 0.007.
- Sau scaler: hệ số PC1 là 0.643, 0.688, 0.335. Giờ ngủ vào trục.
- Dấu của một trục PCA có thể đảo. Hình dùng trị tuyệt đối.

Học không giám sát
Mục lục
Không có y
K-means
PCA
Mẫu dài
15 Phương sai
Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Cả hai đều chỉ nhận X

```
KMeans(n_clusters=3, n_init=10, random_state=261)
PCA(n_components=2, random_state=261)
```

- Cả hai nằm sau `StandardScaler`, trong một pipeline.
- `fit_predict` và `fit_transform` chỉ nhận `X`, shape `(200, 3)`.
- Không có `y`, nên không có `classification_report`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Giới hạn cần mang theo

- Không gọi cụm 80 là một nhóm ổn, hay là một ngành.
- Không chấm accuracy giữa nhãn cụm và `needs_support`. Hai bộ nhãn không cùng nghĩa, và đổi số $0, 1, 2$ làm accuracy đổi.
- Nhìn mặt phẳng PCA rồi kết luận các cụm đã tách rời thì bỏ mất `0.320` phương sai.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Kiểm tra

ltsach@hcmut.edu.vn
Thanh-Sach LE

Câu hỏi

Ba cụm có cỡ 59, 80, 61. Ba ngành có 76, 62, 62 dòng. Inertia từ $k = 3$ sang $k = 4$ giảm từ `343.0` xuống `273.0`.

1. Cụm 80 có phải ngành CS không?
2. Inertia giảm có nghĩa $k = 4$ đúng hơn không?
3. Vì sao deck này không báo F1?

ltsach@hcmut.edu.vn
Thanh-Sach LE

Đáp án

- Không. 80 không trùng 76, và nhãn cụm không được học từ cột ngành.
- Inertia giảm vì có thêm một tâm. Đó là định nghĩa của tổng bình phương khoảng cách.
- F1 cần một nhãn đúng. Phép fit này không nhận `needs_support`.

Làm tiếp trong notebook ở `samples/`.

ltsach@hcmut.edu.vn
Thanh-Sach LE

Tổng kết

- **K-means** gán dòng vào tâm gần nhất, rồi cập nhật tâm bằng trung bình.
- k là hyperparameter. Inertia `439.4`, `343.0`, `273.0` giảm khi k tăng.
- Cỡ 59, 80, 61 không phải ba ngành 76, 62, 62.
- Trên đám dài, PC1 giữ `0.990`, nên bỏ được PC2. Trên ba cột giờ học, hai trục chỉ giữ `0.680`.
- Không scale thì PC1 gần như chỉ còn giờ học. Sau scaler, giờ ngủ cũng vào trục.
- Cả hai phép không có target, nên không có F1.

ltsach@hcmut.edu.vn
Thanh-Sach LE